CSV置くだけ構成は壊れずに間違う

秋田のオープンデータで検証するS3 Tables

JAWS-UGビッグデータ支部 織田 繁

#jawsug #jawsfesta2026

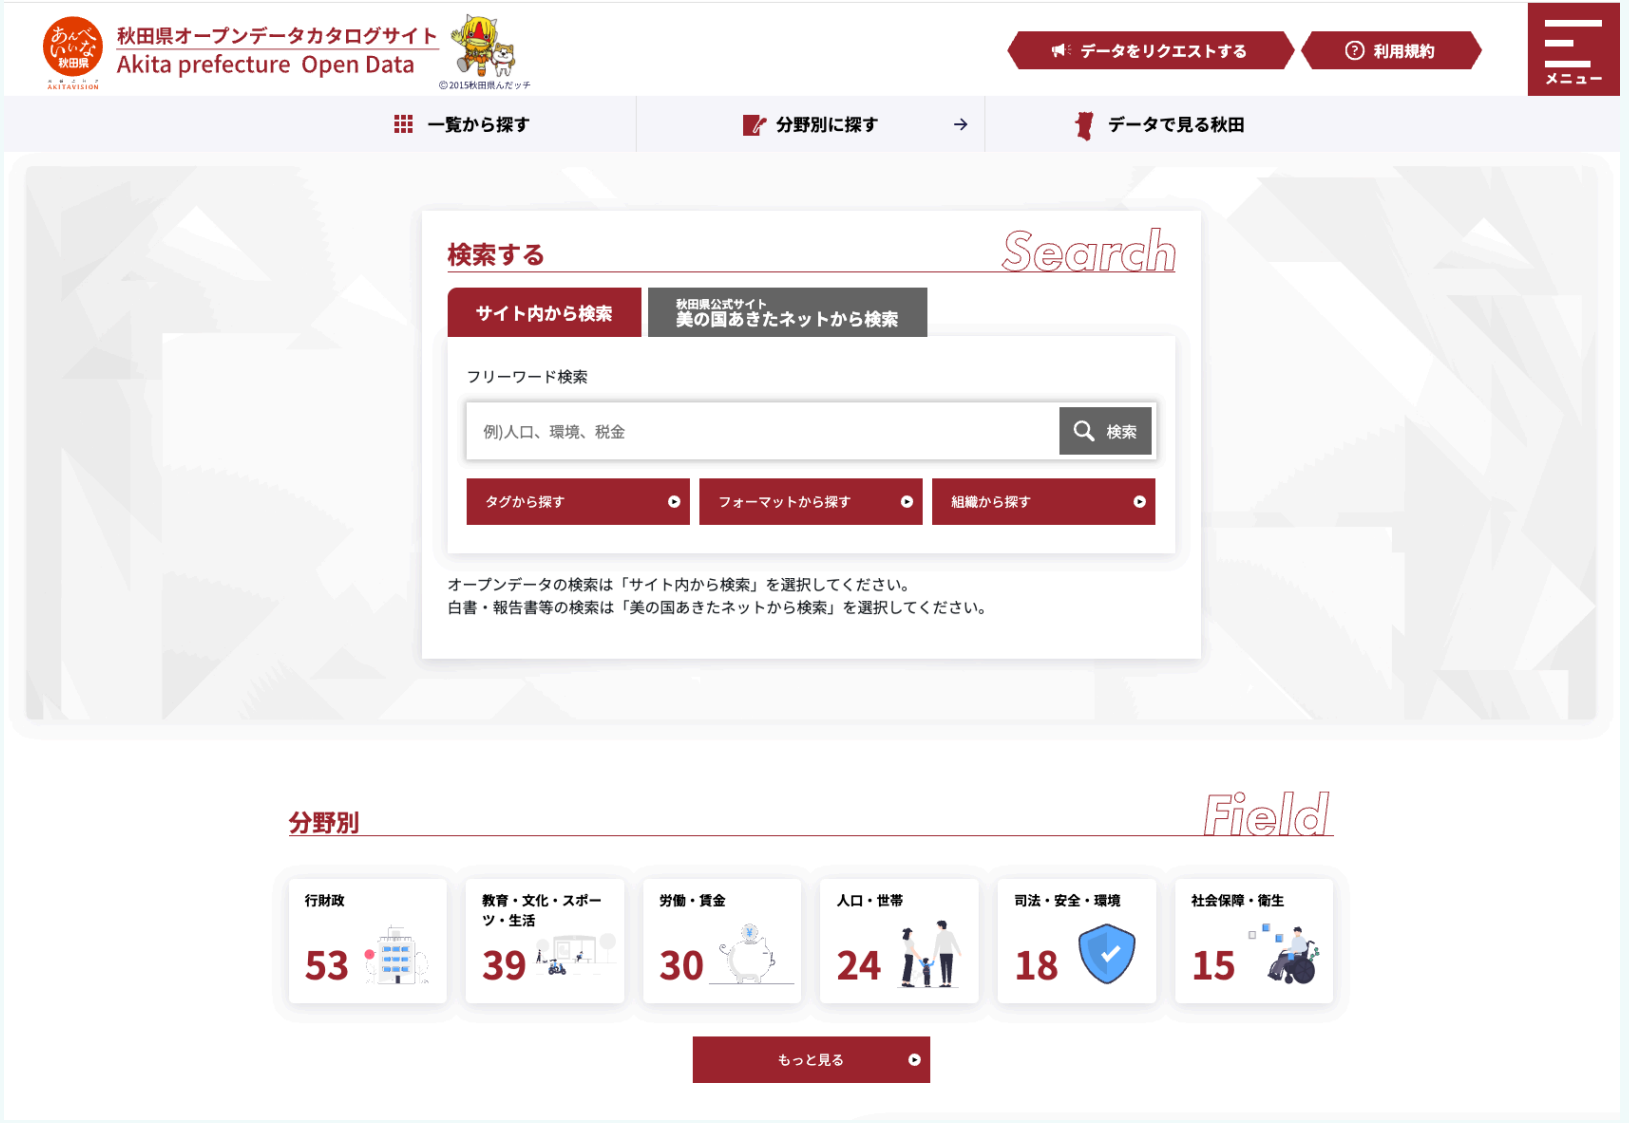


自己紹介

Shigeru Oda

- Community
  - AWS Community Hero
  - JAWS-UG ビッグデータ支部 運営
  - JAWS-UG 初心者支部 運営
- Sansan株式会社 技術本部
  - Sansan Engineering Unit Infrastructure Group
  - Data Intelligence Engineering Unit Infrastructure Group

秋田県オープンデータカタログサイト



JAWS FESTA 2026 in AKITA

利用できるデータセット

17分野・264データセット、詳細なデータセットについては後述する付録を参照

分野	件	例
行財政	53	市町村決算、県民意識調査、市町村コード一覧
教育・文化・生活	39	小中高・特別支援学校一覧、放課後児童クラブ
労働・賃金	30	毎月勤労統計、Aターン就職者統計
人口・世帯	24	年齢別人口流動調査（月報・年報）、人口移動理由
司法・安全・環境	18	交通事故発生状況、特殊詐欺被害、海岸漂着ごみ
社会保障・衛生	15	病院名簿、病床機能報告、保護状況
エネルギー・水／国土・気象	21	風力・地熱・メガソーラー、指定避難所、津波想定
ほか9分野 ＋ 分野なし	66	工業団地情報、クマダス（クマ目撃）、在住外国人数

データセットのチェックの仕方

外部から手に入れたデータセットでのチェックの仕方を一例としてお伝えします。

県・市町村の年齢各歳、男女別人口というデータセットを利用しています。

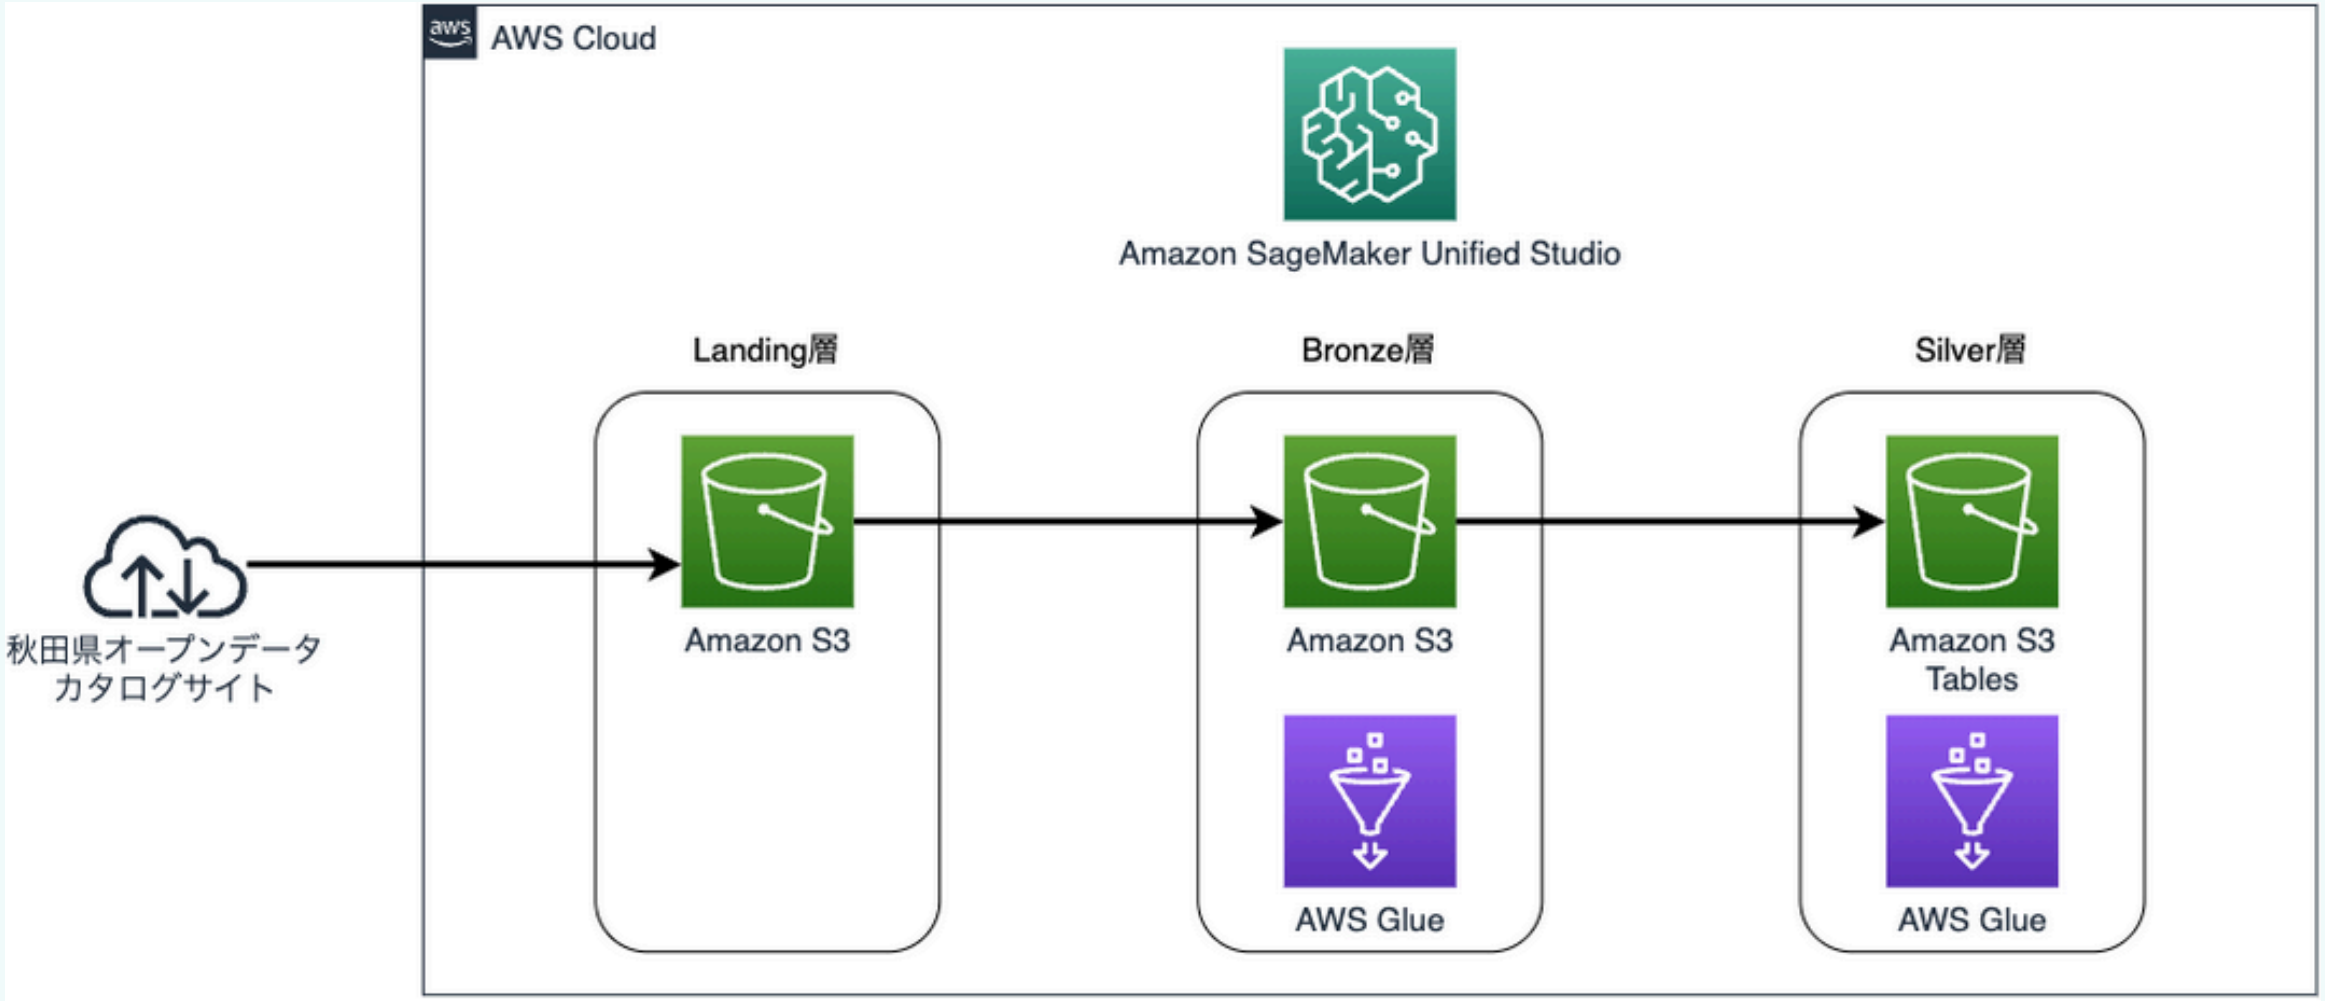
項目	内容
期間	1980～2025年
ファイル	5年ごとに1本、計9本のCSV（UTF-8 BOM付き）
地域	秋田県計 ＋ 市町村
行	年 × 地域 × 男女別（男女計・男・女）
列	年月日コード・年月日・市町村コード・市町村・男女別・総数・0～100歳以上の各歳・5歳階級

Sampleデータ

`pref_nenreikakusai_2020.csv` の1行(2025年・秋田県・男女計)

カラム	値
年月日コード	2025001001
年月日	2025年10月1日現在
市町村コード	5000
市町村	秋田県
男女別	男女計(人)
総数	878,798
0歳(1歳刻み)	3,068
0〜4歳(5歳刻み)	18,782

データセットのチェックの仕方 構成図



データセットのチェックの仕方 Landing層

方針

- 文字コード・改行コード・構造だけをそろえること
- 型とデータの中身は見ない（Bronze / Silver で扱う）

チェック内容

- 文字コードがUTF-8であるか または 変換可能であること
- 改行コードはLFであるか または 変換可能であること
- 構造化データ または 半構造化データでTable変換可能であること
- ”で囲みがないこと(”,”などのエスケープされたカンマがあることを危惧)
- 列数がヘッダとデータで差異はないこと
- 空行がないこと

データセットのチェックの仕方 Bronze層

方針

- 元データの内容を型変換などせず素直に取り込むこと
- 全カラムString型とすること
- 単項目・簡単な相関チェックを実施すること

チェック内容

- CSVファイルとTable件数が同じであること
- 数値型となる想定の列は数値変換が可能であること
- 合算の計算があうこと
- キー重複がないこと
- 男女計・男・女が1行ずつあるか

データセットのチェックの仕方 Silver層

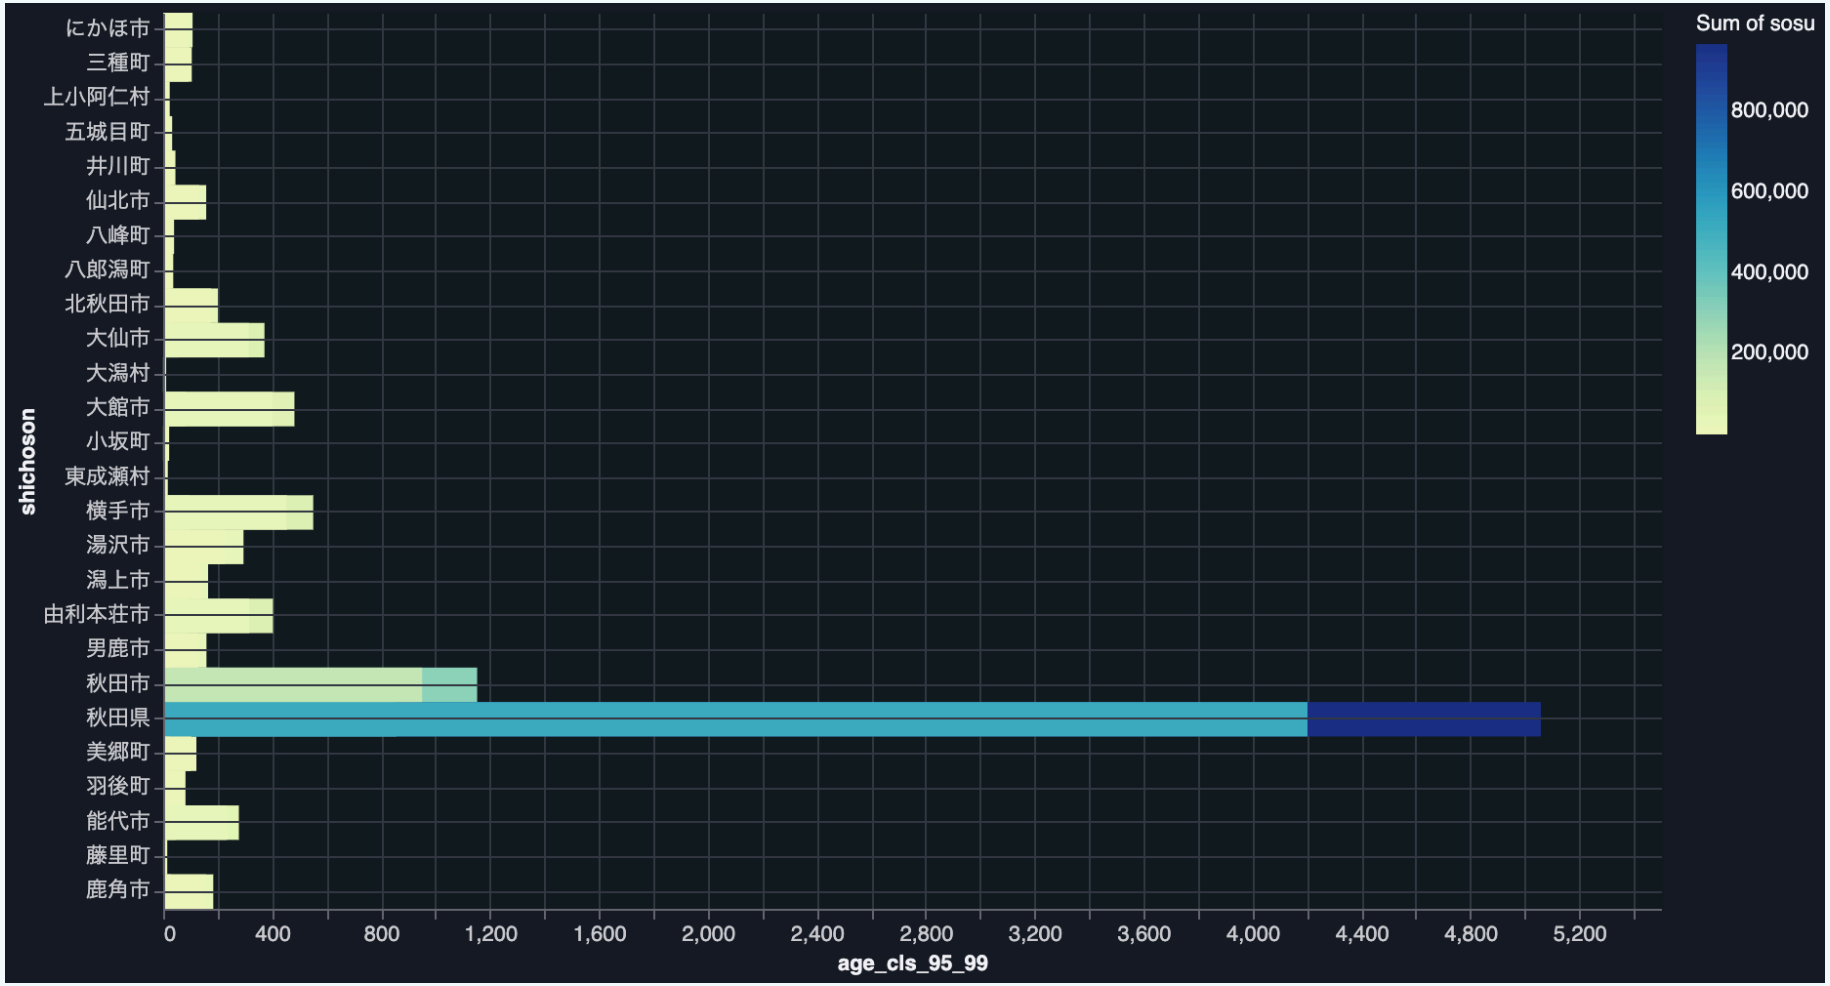
方針

- Bronze の String に型を付けること（人数の列は long）
- 数値にならない - は NULL にすること（0 にはしない）
- マイナスの値は推計値としてそのまま残し、件数を記録すること
- 可視化でのチェックを行うこと

チェック内容

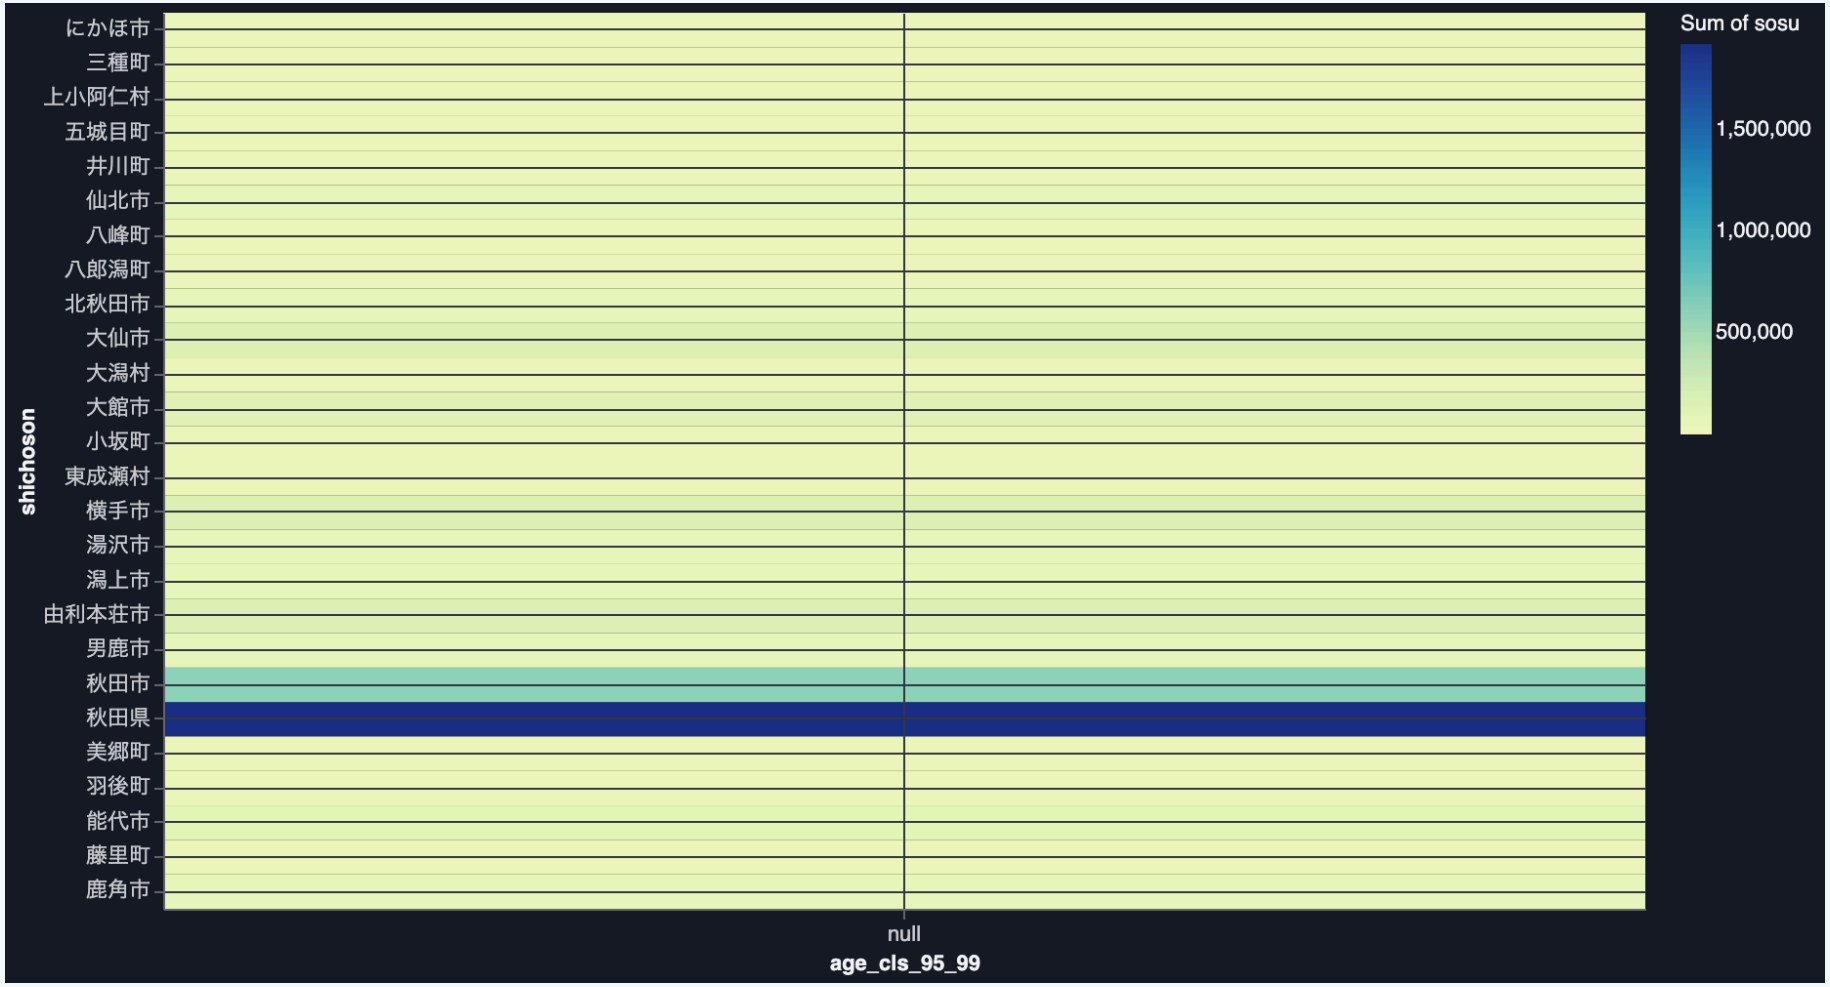
- Bronze層と件数が同じであること
- 5歳階級の推移を可視化
- 人口ピラミッドを可視化
- '-'とマイナスの分布を可視化
- 総数の推移を可視化
- 数値カラムごとのNULLとマイナスを可視化
- 年 × 各歳のヒートマップ可視化

2019年のデータ 95～99歳



JAWS FESTA 2026 in AKITA

2020年のデータ 95～99歳 -> 全データがNull



JAWS FESTA 2026 in AKITA

年齢不詳カラムが消えていた

年月日	市町村	男女別	総数	0歳	・・・	100歳以上	年齢不詳	0~4歳	・・・	90~94歳	95~99歳
2019年10月1日現在	秋田県	男女計（人）	965927	4875	・・・	617	8540	26889	・・・	21031	5059
2019年10月1日現在	秋田市	男女計（人）	306178	1864	・・・	154	5978	9894	・・・	5059	1153
2019年10月1日現在	能代市	男女計（人）	50842	212	・・・	52	1240	1192	・・・	1168	278
2019年10月1日現在	横手市	男女計（人）	86499	444	・・・	44	304	2422	・・・	2189	551
2019年10月1日現在	大館市	男女計（人）	70085	387	・・・	67	224	1950	・・・	1614	482

TRUE TRUE TRUE TRUE TRUE ・・・ TRUE FALSE FALSE ・・・ FALSE FALSE

年月日	市町村	男女別	総数	0歳	・・・	100歳以上	0~4歳	5~9歳	・・・	95~99歳
2020年10月1日現在	秋田県	男女計（人）	959502	4370	・・・	738	25345	31355	・・・	5570
2020年10月1日現在	秋田市	男女計（人）	307672	1704	・・・	177	9476	11278	・・・	1337
2020年10月1日現在	能代市	男女計（人）	49968	188	・・・	50	1089	1314	・・・	323
2020年10月1日現在	横手市	男女計（人）	85555	390	・・・	60	2292	2893	・・・	579
2020年10月1日現在	大館市	男女計（人）	69237	294	・・・	52	1760	2139	・・・	432

Amazon AthenaはCSVのヘッダ名を確認していない

予想されるスキーマ更新のタイプ	CSV / TSV（ヘッダー有無とも）	JSON	AVRO	PARQUET 名前で読む（既定）	PARQUET インデックスで読む	ORC インデックスで読む（既定）	ORC 名前で読む
列の名前変更	Y	N	N	N	Y	Y	N
テーブルの先頭または中間に列を追加する	N	Y	Y	Y	N	N	Y
テーブルの末尾に列を追加する	Y	Y	Y	Y	Y	Y	Y
列の削除	N	Y	Y	Y	N	N	Y
列の順序変更	N	Y	Y	Y	N	N	Y
列のデータ型の変更	Y	Y	Y	Y	Y	Y	Y

- Y = その形式はこのスキーマ変更に対応している（クエリを変えずに読み続けられる）
- N = 対応していない（CSV は位置で読むのでエラーにならず、値がずれたまま返る）

出典: Amazon Athena ユーザーガイド「スキーマの更新を処理する」の表「Athena におけるスキーマ更新とデータ形式」

【参考】DuckDBの場合

更新タイプ	CSV 既定	CSV union_by_name	CSV 位置指定	Parquet 既定	Parquet union_by_name	JSON union_by_name	AVRO （avro拡張）
列の名前変更	エラー	NULL	○	エラー	NULL	NULL	エラー
先頭または中間に列を追加	○	○	ズレ	○	○	○	○
末尾に列を追加	○	○	○	○	○	○	○
列の削除	エラー	NULL(正しい)	ズレ	エラー	NULL(正しい)	NULL(正しい)	エラー
列の順序変更	○	○	ズレ	○	○	○	○
列のデータ型の変更	文字列	文字列	エラー	エラー	文字列	文字列	エラー

○=全行の値が正しい / NULL=値が取れず NULL / ズレ=別の列の値が入る / 文字列=型が広がりそのまま入る / エラー=読み込み失敗
DuckDB 1.5.6 で実測
位置指定の型変更は DuckDB ではエラー。Athena は数値列に読めない値が来ると NULL を返す

Parquet化すれば課題は解決するのでは？

変更の種類	CSV 位置で読む	Parquet 名前で読む （Athena既定）	Iceberg field ID で読む
列の削除	値がずれる	NULL（正しい）	NULL（正しい）
先頭・中間に追加	値がずれる	影響なし	影響なし
列の順序変更	値がずれる	影響なし	影響なし
列の名前変更	気づけない	NULL / エラー	影響なし（RENAME した場合）

今回の `年齢不詳` は「列の削除」なので、Parquet化すれば正しく読めます
一方で名前が変わる場合もあり、この課題には Iceberg が有効です（名前ではなく field ID で同定するため）

Parquet で足りるか、Iceberg にするか

ファイル形式の話ではなく、テーブルとして持つか否かの話

	S3 に置く（CSV / Parquet）	S3 Tables（Iceberg）
スキーマの検査	読むときに当てるだけ。定義とファイルが食い違っても通る場合がある	書くときに検査。合わないDMLは失敗する
列が変わった履歴	定義の履歴は Glue に残るが、ファイルとの対応は残らない	スキーマの版が残る（古い snapshot は当時の列で読める）
書き込み	置き換えの途中が見える	アトミックなコミット
過去の数字の再現	自分で版を管理	time travel（snapshot ID で戻れる）
遡った訂正	ファイルを作り直す	UPDATE / DELETE / MERGE INTO

右列は Athena + S3 Tables で実測（合わない INSERT は TYPE_MISMATCH で失敗し snapshot も増えない）

判断の軸はデータ量ではなく、列が変わるかどうか

自分のデータが…	S3 + Athena(CSV)	S3 に Parquet	S3 Tables(Iceberg)
列の構成が変わらない	十分	十分	過剰
列が増減する	値がずれる	読める	読める
列の名前が変わる	気づけない	NULL / エラー	影響なし(RENAME した場合)
過去の版を遡りたい	自分で運用	自分で運用	snapshot
書き込みが同時に走る	途中の状態が見える	同じ	アトミック(仕様。未検証)

列が動かないなら、置くだけで十分です。この規模では CSV 直読みのほうが速い

Athena で同じ集計を5回ずつ実測(中央値): CSV 552 ms / S3 Tables 1,448 ms

まとめ

- 年に一度スキーマが変わるデータを CSV で置くと、エラーを出さずに間違った数字を返す
- 件数も合計も合うので、素朴なデータ品質チェックはすり抜ける
- IcebergなどTableデータとして格納する前提でチェックフローを組むことで、CSV+Athenaでは気がつけない課題も検知できる

出典と検証コード

この資料は以下の著作物を改変して利用しています。

- 秋田県オープンデータカタログサイト
- クリエイティブ・コモンズ・ライセンス 表示 4.0

検証コードとデータ台帳: https://github.com/shigeru-oda/jaws-festa-2026

付録: 収録データセット全件

264データセット / 201系列 / 2026-10-04 時点



付録: 記号の意味

記号	意味
（なし）	CSV 配布あり。S3 に置いて Athena / S3 Tables でそのまま読める
[Excel]	CSV 配布がなく XLS/XLSX のみ。取り込み前に変換が必要
[Word]	DOC/DOCX を含む。表ではなく報告書の本文
[Geo]	GeoJSON を含む。264件中2件だけ
[ZIP]	ZIP でまとめ配布。中身は Excel 一式・CSV 一式・GIS など
[API]	CSV に加えて JSON/RDF/XML を揃えている
xN	同じ表の年次違いが N 件

付録: 人口・世帯(24件 / 24系列)

- 年齢別人口流動調査(月報)[API]
- 年齢別人口流動調査(月報バックナンバー)[API]
- 年齢別人口流動調査(年報:2025年 秋田県の人口)
- 年齢別人口流動調査(年報時系列データ)[API]
- 年齢別人口流動調査(県・市町村の年齢各歳、男女別人口)
- 人口移動理由実態調査(2025年度 調査報告書)[Excel]
- 人口移動理由実態調査(時系列データ:2013年以降)[API]
- 住民基本台帳人口
- 国勢調査 [Excel][Word]
- 市町村別人口(4月現在)[Excel][Geo]
- 秋田県衛生統計年鑑 [Excel][Word]
- 自殺者数の状況 [Excel]
- 都市計画基礎調査 x12(秋田市・大仙市・由利本荘市・北秋田市・仙北市・鹿角市・潟上市・男鹿市・にかほ市・美郷町・五城目町・小坂町)

付録: 教育・文化・スポーツ・生活(39件 / 30系列)

- 子ども・若者行政関係資料 x5
- 子ども・若者を取り巻く状況 x4
- 第2次あきた子ども・若者プランに基づく施策の実施状況 x2
- 第3次あきた子ども・若者プランに基づく施策の実施状況 x2
- 第2次・第3次あきた子ども・若者プランに基づく施策の実施状況
- 子ども・若者支援機関一覧
- 学校一覧 x5(小学校・中学校・高等学校・特別支援学校・義務教育学校)
- 幼稚園・保育所・認定こども園一覧
- 地域型保育実施施設一覧
- 認可外保育施設一覧
- 放課後児童クラブ一覧
- 新・放課後子ども総合プラン実施箇所一覧
- あきた子育てふれあいカード協賛店一覧 [API]
- 教育委員会一覧
- 社会教育施設一覧(生涯学習・社会教育関係)
- 社会教育施設一覧(文化・芸術関係)
- 確認大学等一覧(高等教育の修学支援新制度)
- 私立専修学校・各種学校一覧 [Excel]
- 秋田県立衛生看護学院 入学・就職状況 [Excel]
- 学校基本調査結果 [Excel]
- 学校保健統計調査結果 [Excel]
- 社会生活基本調査 [Excel]
- スポーツ実態調査
- 総合型地域スポーツクラブ設置数
- 生活衛生課業務概要 [Excel]
- 宗教法人名簿

付録: 行財政(53件 / 30系列)

- 決算概況 [Excel][Word] x8
- 財務書類 [Excel] x8
- 県民意識調査 [ZIP] x5
- 税務統計書 x4
- 秋田市消費者物価指数(月報)[Excel] x3
- 秋田市消費者物価指数(年報)[Excel]
- 秋田市消費者物価指数(グラフ)[Excel]
- 秋田県税務統計書
- 秋田県財務規則 [Word]
- 不服申立ての処理状況 [Excel]
- 免許人口 [Excel]
- 固定資産の価格等の概要調書 [Excel]
- 固定資産の提示平均価額 [Excel]
- 地方公営企業の抜本的な改革等の取組状況 [Excel]
- 審議会等一覧
- 市町村公営企業概要 [Excel]
- 市町村公営企業経営比較分析表 [Word][ZIP]
- 市町村別市町村税の税率一覧 [Excel]
- 市町村所在地・コード一覧
- 市町村決算(普通会計)の状況 [Excel]
- 市町村特別職(市町村長・議長等)一覧
- 市町村税の徴収実績 [Excel]
- 市町村税の課税状況等 [Excel]
- 市町村財政の健全化の状況 [Excel]
- 市町村財政指標 [Excel]
- 指定管理者制度の導入状況
- 県内市町村のラスパイレス指数 [Excel]
- 県内市町村職員数
- 知事所管公益法人等一覧
- 行政手続のオンライン化の状況 [Excel]

付録: 社会保障・衛生（15件）／ 労働・賃金（30件）

- 社会保障・衛生: 病床機能報告における病床の状況 [Excel] x5
- 社会保障・衛生: 病院名簿 [Excel]
- 社会保障・衛生: 特定健診・後期高齢者健診 実施医療機関一覧表 [Excel]
- 社会保障・衛生: 市町村別国保税一覧 [Excel]
- 社会保障・衛生: 障害者等用駐車区画利用制度協力施設一覧 [Excel]
- 社会保障・衛生: 社会福祉施設・法人便覧 [Word][ZIP]
- 社会保障・衛生: 福祉事務所一覧 [Word]
- 社会保障・衛生: 秋田県内の救急医療体制 [Word]
- 社会保障・衛生: 秋田県衛生統計年鑑 [Excel][Word]
- 社会保障・衛生: 新型コロナウィルス感染状況関連データ
- 社会保障・衛生: 保護状況
- 労働・賃金: 労働条件等実態調査その1～その5 [Excel] x19
- 労働・賃金: 毎月勤労統計調査地方調査結果（月報）[Excel] x5
- 労働・賃金: 毎月勤労統計調査地方調査結果（年報）[Excel]
- 労働・賃金: 出稼労働者推計調査結果 [Excel] x2
- 労働・賃金: Aターン就職者に関する統計情報 [Excel]
- 労働・賃金: 秋田県の労働組合組織状況 [Excel]
- 労働・賃金: 県内の地域おこし協力隊活動状況 [Excel]

付録: 司法・安全・環境(18件)／ 国土・気象(10件)

- 司法: 犯罪統計資料 [Excel]
- 司法: 交通事故発生状況 [Excel]
- 司法: 特殊詐欺被害認知状況 [Excel]
- 司法: SNS型投資・ロマンス詐欺被害認知状況 [Excel]
- 司法: 警察安全相談受理状況
- 司法: 遺失物・拾得物件・遺失者返還の取扱状況について
- 司法: 航空隊ヘリ出動状況
- 環境: 海岸漂着ごみ組成調査結果 [Excel] x5
- 環境: 河川ごみ組成調査結果 [Excel] x2
- 環境: 河川ごみ組成調査 [Excel]
- 環境: 温室効果ガス排出量 [Excel]
- 環境: 廃棄物処理法違反検挙状況
- 環境: 建築物における衛生的環境の確保に関する登録事業者一覧
- 国土: 地震被害想定データ(震度分布図・液状化危険度分布図)その1～3 [ZIP] x3
- 国土: 地震被害想定データ(被害想定結果)その1～3 [Word] x3
- 国土: 津波浸水想定データ [ZIP]
- 国土: 指定避難所・指定緊急避難場所 [Excel]
- 国土: 都市計画に関するデータ [API]
- 国土: 降積雪データ [Excel]

付録: エネルギー・水(11件)／ 企業・家計・経済(9件)

- エネルギー: 風力発電の導入状況
- エネルギー: 水力発電の導入状況
- エネルギー: 地熱発電の導入状況
- エネルギー: バイオマス発電の導入状況
- エネルギー: メガソーラーの導入状況
- エネルギー: 県営水力発電所一覧
- エネルギー: 県営水力発電所発電電力量
- 水: 給水事業所一覧
- 水: 実績給水量及び料金収入
- 水: 工業用水道施設の概要
- 水: 汚水処理人口普及率 [Excel]
- 経済: 県民経済計算 [Excel]
- 経済: 市町村民経済計算 [Excel]
- 経済: 秋田県産業連関表 [Excel]
- 経済: 経済センサス－活動調査集計結果(秋田県の概要)[Excel]
- 経済: 景気動向指数 [Excel]
- 経済: 県内経済動向調査 [ZIP]
- 経済: 秋田市消費者物価指数(月報)[Excel]
- 経済: 建築着工統計調査(グラフ)[Excel]
- 経済: 東北地域百貨店・スーパー販売額動向(グラフ)[Excel]

付録: 農林水産・鉱工業・商業・運輸・住宅土地(20件)

- 農林水産: 秋田県農林水産業累年統計表 [ZIP]
- 農林水産: 農林業センサス農林業経営体調査 [Excel][Word]
- 農林水産: 農林業センサス農林業経営体調査結果 [Excel][Word]
- 農林水産: 2018年漁業センサス漁業経営体調査 [Excel]
- 農林水産: 認定農業者の認定状況 [Excel]
- 農林水産: 森林情報公開サービス
- 鉱工業: 鉱工業生産指数 [Excel]
- 鉱工業: 秋田県の工業 [Excel]
- 商業: 商業統計調査 [Excel]
- 商業: 旅館業許可施設一覧
- 商業: 集中調達物品契約状況 [Excel]
- 運輸観光: 秋田県観光統計 [Excel]
- 運輸観光: 秋田空港利用者数(グラフ)[Excel]
- 運輸観光: 港湾取扱貨物量(グラフ)[Excel]
- 運輸観光: 乗合バス・第三セクター鉄道輸送人員 [Excel]
- 運輸観光: 交通量調査結果
- 運輸観光: 秋田のみちの現状
- 住宅土地: 住宅・土地統計調査 [Excel][Word]
- 住宅土地: 建築着工統計調査結果 [API]
- 住宅土地: 屋外広告業登録業者一覧 [API]

付録: 国際・情報通信・その他(13件 / 10系列)

- 国際: 秋田県の貿易(統計版)x4
- 国際: 在住外国人数
- 情報通信: オープンデータ一覧
- 情報通信: 県提供公衆Wi-Fiアクセスポイント一覧
- その他: ツキノワグマ等情報マップシステム『クマダス』データ [API]
- その他: 工業団地情報
- その他: 都市計画基礎調査(男鹿市)
- その他: 児童相談所業務概要に係る相談の受付及び処理状況 [Excel]
- その他: 秋田県認証 NPO法人一覧 [Excel]
- その他: 秋田県知事における認定(特例認定)法人一覧 [Excel]

付録: 分野が付いていない24件(22系列)

- 労働条件等実態調査その1～その5 [Excel] x5
- 子ども・若者を取り巻く状況 x2
- 県民意識調査 [ZIP] x2
- 子ども・若者行政関係資料
- 第3次あきた子ども・若者プランに基づく施策の実施状況
- 幼稚園・保育所・認定こども園一覧
- 毎月勤労統計調査地方調査結果(月報)[Excel]
- 出稼労働者数推計調査結果 [Excel]
- 秋田市消費者物価指数(月報)[Excel]
- 秋田県産業連関表 [Excel]
- 秋田県の貿易(統計)
- 財務書類 [Excel]
- 海岸漂着ごみ組成調査結果 [Excel]
- 2023年漁業センサス漁業経営体調査 [Excel]
- 都市計画基礎調査 x2(大館市・八郎潟町)
- 県の公共施設等の見える化 [Geo]
- アオコ発生状況