CSV置くだけ構成は壊れずに間違う

秋田のオープンデータで検証する S3 Tables

織田繁





#jawsug #jawsfesta2026

今の秋田

人口	878,798人（2025年10月）
ピーク	1981年 1,257,411人 → 30.1% 減
直近	864,753人（2026年7月）
年齢	65歳以上 40.1% ／ 75歳以上 201,669人 ／ 15歳未満 8.6%
減り方	自然減 13,803人 ／ 社会減 3,434人 → 減少の 80% は自然減

この4つを県のCSVから出す

素朴な構成で出す

	素の S3 + Athena	S3 Tables
置き方	CSVをそのまま置く	テーブルバケットに取り込む
定義	Glueにテーブルを作る	Icebergのスキーマ
費用	スキャンした分だけ	ストレージ + 監視 + 圧縮
手間	数分	取り込み直しが必要

数メガバイトの自治体データ。Icebergが必要な規模ではない

秋田県オープンデータカタログサイト

264 データセット ／ 2,259 リソース ／ 11 形式(CKAN)

	データセット数
CSV を持つ	114
Excel を持つ	187
うち CSV が1本もない	138
分野が付いていない	24

CSVは少数派。半分以上は S3 に置く前に変換が必要

題材: 月報人口CSV

```
pref_jinkousetai_2020.csv   36列 / 408行
pref_jinkousetai_2024.csv   36列 / 408行
pref_jinkousetai_2025.csv   36列
pref_jinkousetai_2026.csv   36列
```

市町村別の人口・出生死亡・転入転出。年度ごとに1ファイル

やりたいこと: 年度をまとめて1つのテーブルとして読む

第1段: 2024年に26列の名前が変わった

36列 → 36列。26列が改称。挿入・削除・並べ替えは 0 件

位置	2020年版	2024年版
20	県外転入・男女計(人)	転入・合計(人)
23	県内転入・男女計(人)	転入・県内計(人)
24	転入・県外計(人)	転入・県外計(人)

並び順は36列すべて同一。変わったのはラベルだけ

「県外転入」は県外転入ではなかった

位置20 ＝ 位置23（県内）＋ 位置24（県外）。396行すべて一致

2020年版	県外だと信じた値	実際の県外	過大
市部計	1,125人	639人	76%
郡部計	104人	45人	131%
県計	11,711人	11,711人	一致する

県計では県内が空欄なので検算が通る。市町村別に落とした瞬間に間違う

なぜ気づけないのか

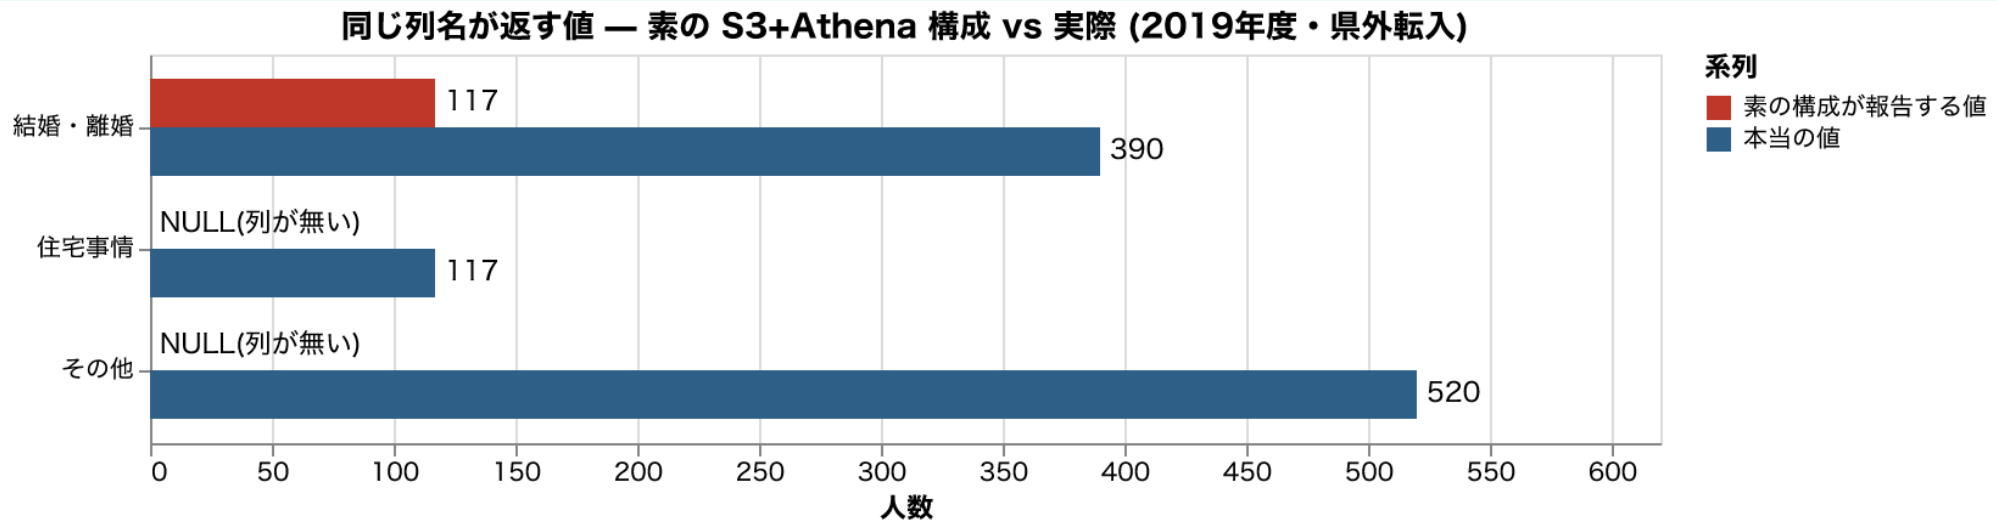
2020年版の定義で両方を読む → 816行・エラー0・警告0

気づけない理由	中身
ヘッダがクエリに入らない	`skip.header.line.count=1` で1行目を捨てる。列名は処理系に一度も渡らない
検出可能な差分がない	位置・値の意味・行数・型がすべて同じ

実機Athenaでも `information_schema` は旧名のまま（2026-08-13 確認）

列が消えると値がずれる

人口移動理由実態調査。2019年に分類が再編され 19列 → 16列



7項目が別の項目の値を返し、3項目がNULL。検算は1,521行すべて一致する

JAWS FESTA 2026 in AKITA

S3 Tables に入れる

汎用バケットとは別種のテーブルバケット。Athena の CTAS で取り込み直す

	素の CSV	Iceberg
列の同定	位置	field ID
改称	気づけない	スキーマ進化として記録
列の増減	値がずれる	別の列として足される

旧版 19列 + 新版 → 28列。旧版の行は追加された9項目がNULLになる

同じ集計をもう一度

冒頭の4つの数字を S3 Tables の上で出し直す

	素の S3 + Athena	S3 Tables
列名が変わった年	静かに間違う	同じSQLで取れる
分類が変わった年	値がずれる	同じSQLで取れる
再編前に戻る	自分でフォルダを切る	snapshot

回答総数は2019年に 4,481人 → 6,413人（43.1%増）。比較の可否は統計側の判断

「マネージド」の中身

```
iceberg_compaction                = { status = "enabled", target_file_size_mb = 64 }
iceberg_snapshot_management       = { max_snapshot_age_hours = 168, min_snapshots_to_keep = 5 }
iceberg_unreferenced_file_removal = { unreferenced_days = 3, non_current_days = 1 }
```

コンパクションとスナップショット管理はテーブル単位、未参照ファイルの削除はバケット単位

私のデータではコンパクションの出番がなかった（ファイル2個・数十キロバイト）

パフォーマンス実測

ローカル実測	サイズ	全件スキャン
CSV 2ファイル	143.5 KB	0.9 ms
Iceberg	39.0 KB	3.5 ms

実機Athenaのスキャン量は1クエリ 129,354 / 146,928 bytes（2ファイル全体）

Athenaの課金は1クエリ最小10MB。この規模では最小課金が支配する

判断軸はデータ量ではない

自分のデータが…	素の S3+Athena	S3 に Parquet	S3 Tables
列の構成が変わらない	十分	◎	過剰
列名が変わる	気づけない	名前で読む	進化として記録
列が増減する	値がずれる	○	◎
過去の版を遡りたい	自分で運用	自分で運用	snapshot
同時書き込み	中途半端な状態が見える	同じ	アトミック
数MB程度	安くて速い	◎	監視・圧縮の費用が乗る

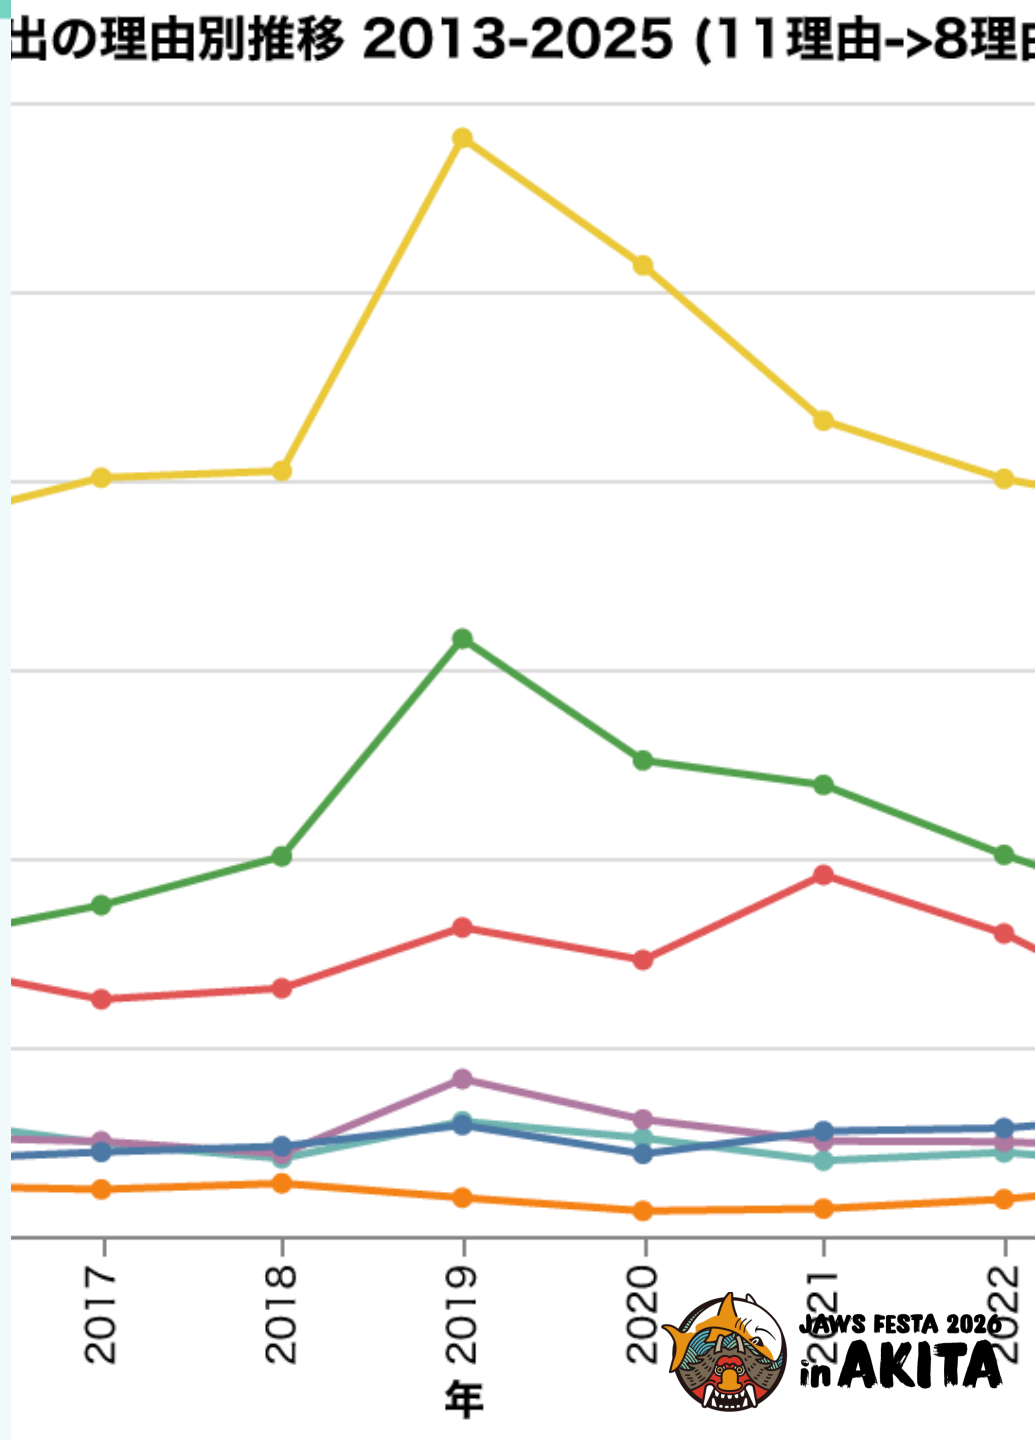
年に一度スキーマが動くデータなら、置くだけ構成は危険

秋田のデータが言っていること

2025年度・県外転出 4,705人の理由

	転出	転入
転職・就職	27%	23%
退職・同居	242人	776人

出ていくのは仕事で、戻ってくるのは暮らし



予備: Q&A の材料



Q&A の材料

想定質問	答えの材料
Parquetでは?	名前で読むのでリネームも増減も可。過去の版と同時書き込みのアトミック性は付いてこない
Glue Crawlerを再実行すれば?	列名は更新されるので気づける。ただし位置がずれる変更では再クロールが逆に壊す
県計では一致するのでは?	一致する。だから県計で検算すると通ってしまう
DuckDBで代替できる?	列数不一致をエラーにする。共有・権限・同時書き込みが要るならS3側
コンパクションで速くなる?	私のデータでは出番がなかった(ファイル2個)。GB級で試すべき

出典と検証コード

秋田県オープンデータポータルサイト を加工して作成 / CC BY 4.0

他県比較: 39都道府県を調査。19ファイル中11がShift_JIS、ヘッダが1行目にない県が4件（長崎8行目・徳島5行目・佐賀3行目・北海道2行目）

検証コードとデータ台帳: github.com/shigeru-oda/jaws-festa-2026